



Universidade do Minho

Departamento de Informática

Mestrado (Integrado) em Engenharia Biomédica

Ramo de Informática Médica

Imagiologia

1º (4º) Ano, 2º Semestre

Ano letivo 2022/2023

Enunciado Prático

23 de maio de 2023

Tema	<i>Visualização de filtros e de feature maps na classificação de imagens com CNNs usando MNIST</i>
Enunciado	Pretende-se, com esta ficha, que seja realizado um conjunto de tarefas que permitam consolidar o conhecimento adquirido sobre Redes Neurais Convolucionais.
Tarefas	<p>Utilizando o <i>framework</i> que preferirem (e, se possível, usando o <i>cuda</i>) devem, numa primeira fase executar as seguintes tarefas (8.visualize_CNN_multiclass_MNIST.ipynb):</p> <p>T1 – Fazer <i>download</i> do <i>dataset</i> MNIST, que consiste em 60000 imagens de dígitos escritos à mão.</p> <p>Executar</p> <pre>wget -c https://repositorio.di.uminho.pt/uploads/f3b502065558d4b72c56aaa157a9b95a.file.mnistcsv.zip -O mnistcsv.zip unzip mnistcsv.zip</pre> <p>T2 – Aplicar as instalações de dependências necessárias (<i>nvcc</i>, <i>torch</i>, <i>liveossplot</i>, <i>pandas</i>, <i>numpy</i>, <i>gdown</i>, ...).</p> <p>T3 – Definir um <i>batch_size</i> de 32.</p> <p>T4 – Na preparação dos dados:</p> <p>T4.1 – Criar as funções de transformação.</p> <p>T4.2 – Aplicar um pré-processamento às imagens, normalizando-as.</p> <p>T4.3 – Ler o <i>dataset</i> e preparar os <i>data loaders</i> com <i>holdout</i>.</p> <p>T5 – Para visualizar os dados em conformidade, colocar primeiramente o <i>label</i> por extenso. Depois, apresentar um <i>batch</i> dos casos de treino para verificar o que se vai trabalhar.</p> <p>T6 – Definir vários modelos para aplicar:</p>

T6.1 – Modelo *CNN* 1:

- *Sequential Composed Layer*
 - *Convolutional Layer*
 - *ReLU activation*
 - *Max Pooling*
- *Sequential Composed Layer*
- *Linear Layer*
- *ReLU activation*
- *Linear Layer*
- *Softmax activation*

Fazer *download* do modelo da BB ([CNNModel_1.pth](#))

T6.2 – Modelo *CNN* 2:

- *Sequential Composed Layer*
 - *Convolutional Layer*
 - *ReLU activation*
 - *Max Pooling*
- *Sequential Composed Layer*
- *Linear Layer*

Fazer *download* do modelo da BB ([CNNModel_2.pth](#))

T6.3 – Modelo *CNN* 3:

- *Sequential Composed Layer*
 - *Convolutional Layer*
 - *Batch Normalization Layer*
 - *ReLU activation*
 - *Max Pooling*
- *Sequential Composed Layer*
- *Linear Layer*
- *Dropout*
- *Linear Layer*
- *Linear Layer*

Fazer *download* do modelo da BB ([CNNModel_3.pth](#))

T6.4 – Modelo *CNN* 4:

- *Sequential Composed Layer*
 - *Convolutional Layer*
 - *Batch Normalization Layer*
 - *ReLU activation*
 - *Max Pooling*
 - *Dropout*
- *Linear Layer*
- *Linear Layer*

Fazer *download* do modelo da BB ([CNNModel_4.pth](#))

T7 – Treinar todos os modelos em separado, registrando os valores de *accuracy* e *loss* para os casos de treino e para os casos de validação.

T7.1 – Modelo *CNN* 1: usar 15 *epochs*, uma *learning rate* de 0.001, usar as funções *Cross Entropy Loss* e a *SGD*.

T7.2 – Modelo *CNN* 2: usar 15 *epochs*, uma *learning rate* de 0.001, usar as funções *Cross Entropy Loss* e a *SGD*.

T7.3 – Modelo *CNN* 3: usar 15 *epochs*, uma *learning rate* de 0.001, usar as funções *Cross Entropy Loss* e a *SGD*.

T7.4 – Modelo *CNN* 4: usar 75 *epochs*, uma *learning rate* de 0.001, usar as funções *Cross Entropy Loss* e a *SGD*.

T8 – Avaliar os modelos em separado, apresentando as previsões e a matriz de confusão.

T9 – Usar os modelos em separado, tentando prever o caso dado.

- Apresentar um *batch* das imagens previstas.
- Imprimir o modelo usado
- Visualizar os pesos do modelo por camadas.
- Visualizar os *feature maps*.
- Aplicar o *max pooling*.
- Percorrer todas as camadas do modelo até à última camada convolucional.
- Visualizar os *feature maps* parciais.

T10 – Submeter um ficheiro *zip* com um documento em *pdf* (ou notebooks) em que se indica, para cada tarefa e para cada modelo, o esquema da rede criada, os hiper-parâmetros utilizados, os valores de *accuracy* e de *loss* obtidos, e os gráficos de aprendizagem.